

《人工智能导论》实验二报告

任务：基于预训练 50 维词向量完成中文影评情感二分类，并比较 MLP、TextCNN、BiRNN、BiLSTM 与 BiGRU 五类模型。

数据集中训练集 19,998 条、验证集 5,629 条、测试集 369 条；词向量覆盖训练语料 token 的 97.18%。

1. 实验任务与流程


实验流程为：读取已经分词的文本样本；仅基于训练集建立词表；从 `wiki\_word2vec\_50.bin` 中抽取词表对应的预训练词向量；将句子截断或补齐到固定长度 80；分别训练 MLP、TextCNN、BiRNN、BiLSTM 和 BiGRU 模型；在验证集上以 F1 为主进行早停，再在测试集上汇报最终结果。

实现中统一采用 Adam 优化器，损失函数为交叉熵。验证集连续若干轮不提升则提前停止，以减少固定训练轮数带来的过拟合风险。

2. 模型结构图与说明


下图将主模型按结构统一绘制为“输入表示 - 特征提取 - 分类输出”的流程图，便于直接比较它们分别依赖的是平均语义、局部短语模式还是双向上下文信息。

图 2-1 MLP 基线模型结构图




MLP 基线模型先将长度不超过 80 的句子映射为 80 x 50 的可微调预训练词向量序列，再根据真实长度对非 PAD 位置做 masked mean pooling，压缩成 50 维句向量。分类头对应代码中的 `Dropout(0.3) -> Linear(50,128) -> ReLU -> Dropout(0.3) -> Linear(128,2)`，参数量较小、训练速度快，但会显式丢失词序信息。

图 2-2 TextCNN 模型结构图



TextCNN 在嵌入层后并行使用 3、4、5 三种卷积核尺寸，每种尺寸配置 128 个卷积核，对应不同长度的局部情感短语窗口。各卷积分支经 ReLU 和时间维最大池化后分别得到 128 维向量，拼接成 384 维句向量，再经过 `Dropout(0.5)` 和全连接层完成二分类，因此它尤其擅长提取“非常失望”“节奏混乱”这类局部触发模式。

图 2-3 BiGRU 模型结构图



BiGRU 先根据真实长度在每个时间步构造掩码，显式跳过补齐位置的状态更新；随后手写双向 GRU 从前向和后向同时编码上下文。分类时仅取最后一层的前向隐藏状态与后向隐藏状态拼接，得到 256 维句向量，并经过 `Dropout(0.3) -> Linear(256,2)` 输出结果。该结构保留了顺序与上下文依赖，但计算成本高于 CNN。

2.1 以图 2-2 的 TextCNN 为例说明单样本如何一步步得到概率

下面给出一个与结构图顺序完全一致的数值化示例，目的是说明“输入样本 -> 卷积特征 -> logits -> softmax 概率”这一整条链路在概率统计层面究竟是如何计算出来的。这个例子为了便于手算，故意把真实实验中的 50 维词向量、多个卷积核和更高维的全连接层缩减成了极简版本，但计算逻辑与正式模型完全一致。

阶段	按照结构图展开的计算过程
----	--------------

1. 输入样本	样本写作“1 你好”时，前面的1是真实标签，表示正类；真正输入TextCNN的文本只有“你好”。为了演示计算过程，假设句长固定为5，因此输入序列补齐为[你好, PAD, PAD, PAD, PAD]。
2. 词嵌入层	为方便手算，把真实实验中的50维词向量缩成2维：你好->[0.8, 0.1]，PAD->[0, 0]。于是输入矩阵可以写成 $x_1=[0.8, 0.1]$ ， $x_2=x_3=x_4=x_5=[0, 0]$ 。这一步对应结构图中的Embedding，把离散词编号映射成连续向量。
3. 卷积层	假设取一个窗口大小为3的卷积核 $W=[[0.6, 0.2], [0.1, -0.1], [0, 0]]$ ，偏置 $b=-0.1$ 。第一个滑动窗口是 $[x_1, x_2, x_3]=[你好, PAD, PAD]$ ，因此卷积得分 $s_1=+b=0.6 \times 0.8 + 0.2 \times 0.1 - 0.1 = 0.40$ 。后两个窗口几乎只含PAD，得分可近似看成0。
4. ReLU 激活	卷积输出经过ReLU： $a_1=\max(0, 0.40)=0.40$ ， $a_2=\max(0, 0)=0$ ， $a_3=\max(0, 0)=0$ 。于是这个卷积核在整句话上的响应序列为[0.40, 0, 0]。ReLU的作用是保留有效激活，同时抑制负值噪声。
5. 最大池化	时间维最大池化得到 $m=\max(0.40, 0, 0)=0.40$ ，表示该卷积核在整句话中检测到的最强局部情感证据强度是0.40。若再假设另一个卷积核经过同样过程得到0.20，则池化后句子特征可写成 $h=[0.40, 0.20]$ 。
6. 全连接层	设输出层对负类和正类的权重分别为 $w_{neg}=[-1.0, 0.0]$ ， $w_{pos}=[2.0, 0.0]$ ，偏置都为0。则 $z_{neg}=w_{neg} \cdot h=-1.0 \times 0.40 + 0.0 \times 0.20 = -0.4$ ； $z_{pos}=w_{pos} \cdot h=2.0 \times 0.40 + 0.0 \times 0.20 = 0.8$ 。这里 z_{neg} 与 z_{pos} 是logits，即未归一化的类别分数。
7. Softmax 概率	将logits变为概率： $P(\text{正类} \mathbf{x})=\exp(0.8)/(\exp(0.8)+\exp(-0.4)) \approx 0.7685$ ， $P(\text{负类} \mathbf{x})=\exp(-0.4)/(\exp(0.8)+\exp(-0.4)) \approx 0.2315$ 。因此模型会预测该样本为正类，这一步就是结构图中Output所对应的概率输出。
8. 交叉熵损失	由于真实标签是1，训练时使用交叉熵 $L=-\log P(\text{正类} \mathbf{x})=-\log(0.7685) \approx 0.2633$ 。若模型给正类的概率越高，这个损失就越小；反向传播会继续调整词向量、卷积核和全连接层参数，让类似正类样本的概率更大。

从这个例子可以看出，TextCNN并不是直接统计“你好”在正类和负类中出现了多少次，而是通过卷积核先抽取局部模式，再把这些模式经过线性层变成logits，最后用softmax构造条件概率 $P(y|\mathbf{x})$ 。训练阶段通过最小化交叉熵，不断调整词向量、卷积核和输出层参数，使正确类别的概率越来越大。

3. 实验参数总表

这张表把每个主模型的结构参数和训练参数放在一起，便于横向比较不同模型的容量、正则化强度和优化策略。


模型	结构参数	训练参数	验证集 F1	测试集 F1	参数量
MLP	hidden_dim=128 dropout=0.3	batch=128 epochs=10 lr=1e-3 wd=1e-4 patience=3 clip=0	0.8480	0.8619	2,673,736
TextCNN	num_filters=128 filter_sizes=3/4/5 dropout=0.5	batch=128 epochs=10 lr=1e-3 wd=1e-4 patience=3 clip=0	0.8422	0.8516	2,744,904
BiRNN	hidden_dim=128 num_layers=1 dropout=0.3	batch=64 epochs=12 lr=8e-4 wd=1e-4 patience=3 clip=5	0.8462	0.8384	2,713,544

BiLSTM	hidden_dim=128 num_layers=1 dropout=0.3	batch=64 epochs=12 lr=8e-4 wd=1e-4 patience=3 clip=5	0.8477	0.8625	2,851,784
BiGRU	hidden_dim=128 num_layers=1 dropout=0.3	batch=64 epochs=12 lr=8e-4 wd=1e-4 patience=3 clip=5	0.8455	0.8525	2,805,704


4. 训练过程曲线

下面给出主实验各模型的训练损失曲线。蓝线表示训练集损失，红线表示验证集损失。大多数模型都能在前几轮快速下降并逐渐趋于平稳，这也说明早停策略有效地减少了后期的无效训练。

MLP 训练曲线



TextCNN 训练曲线



BiRNN 训练曲线







图 4-6 各模型验证集 F1 收敛对比




5. 实验结果展示

模型	最佳轮次	验证集 Acc	验证集 F1	测试集 Acc	测试集 F1	参数量
MLP	7	0.8467	0.8480	0.8645	0.8619	2,673,736
TextCNN	2	0.8424	0.8422	0.8537	0.8516	2,744,904
BiRNN	1	0.8422	0.8462	0.8401	0.8384	2,713,544
BiLSTM	1	0.8428	0.8477	0.8618	0.8625	2,851,784
BiGRU	1	0.8396	0.8455	0.8509	0.8525	2,805,704

五种模型都达到说明文档提出的 80% 以上指标要求，其中测试集表现最好的模型是 BiLSTM，其测试集 Accuracy 为 0.8618，F1 为 0.8625。

图 5-1 主模型测试集 Accuracy/F1 对比



柱状图把表格中的差异直接可视化了出来：BiLSTM 的测试集 F1 最高，MLP 与其非常接近；而 BiRNN 在五个主模型中相对最低。这说明门控循环结构在本任务上整体更稳，但 MLP 这个均值池化 baseline 也已经非常有竞争力。

6. 参数对比分析

对比实验	验证集 Acc	验证集 F1	测试集 Acc	测试集 F1
------	---------	--------	---------	--------

TextCNN (filters=64)	0.8410	0.8404	0.8509	0.8501
BiRNN (hidden=64)	0.8325	0.8390	0.8320	0.8315
BiLSTM (hidden=64)	0.8449	0.8481	0.8428	0.8424
BiGRU (hidden=64)	0.8428	0.8471	0.8428	0.8424

从附加对比实验可以看出，TextCNN 的卷积核数量从 64 提升到 128 后，局部模式提取能力更强；BiRNN、BiLSTM、BiGRU 的隐藏维度从 64 提升到 128 后，也更有利于保留上下文信息，但参数数量和训练时间会同步增加。

7. 模型比较与原因分析

MLP 通过平均池化快速聚合句向量，训练速度最快、结构最简单，但会丢失词序和局部搭配信息，因此更适合作为基础 baseline。TextCNN 对“非常失望”“剧情混乱”这类局部情感短语尤其敏感，参数共享带来较强的效率和泛化能力。BiRNN、BiLSTM 和 BiGRU 则显式建模上下文顺序，更适合处理依赖前后语义的长句；其中 BiLSTM 的门控记忆最完整，BiGRU 在效果和效率之间折中得更明显。

8. 问题思考

(1) 训练何时停止最合适：本实验采用“验证集 F1 早停”。固定迭代次数实现简单，但容易在不同模型和参数下出现欠拟合或过拟合；基于验证集的早停能更贴近泛化能力，不过需要额外划分验证集并增加调参开销。

从图 4-6 的验证集 F1 收敛过程看，BiRNN、BiLSTM 和 BiGRU 的最优轮次分别出现在第 1、1、1 轮，TextCNN 出现在第 2 轮，MLP 则延后到第 7 轮。这与损失曲线后期验证集不再改善的现象一致，也进一步说明早停确实避免了无效训练。

(2) 参数初始化：PAD 向量置零；命中预训练词向量的词直接加载；未命中的词使用与预训练分布同尺度的随机初始化。线性层输入权重使用 Xavier 初始化，卷积层使用 Kaiming 初始化，GRU 的隐藏到隐藏权重使用正交初始化，偏置初始化为 0。这样能在保持数值稳定的同时，更贴合不同层的计算特性。

(3) 如何缓解过拟合：可以使用验证集早停、Dropout、L2 正则、减小模型容量、增加数据增强或引入更多外部语料。对于本实验这种测试集较小的场景，高容量循环模型尤其需要依赖正则化和早停控制泛化误差。

(4) CNN、RNN、MLP 优缺点：MLP 速度最快但忽略顺序；CNN 擅长抽取局部模式、并行度高；普通 RNN 能建模时序但长距离记忆较弱；LSTM 记忆能力最强但参数和训练开销较大；GRU 结构更轻，通常能取得接近 LSTM 的效果。它们分别对应“平均语义”“局部短语模式”“基础时序建模”“强记忆门控”“轻量门控时序建模”几类偏好。

(5) 模型鲁棒性：在额外构造的 6 条影评风格小样本上，主模型整体都能保持较稳定的判断，说明它们对与原任务分布接近的文本仍具备一定一致性；其中普通 RNN 在转折较多的句子上更容易退化，而 LSTM 与 GRU 通常更稳，说明门控结构在保持上下文信息方面更有优势。

样本	真实标签	MLP	TextCNN	BiRNN	BiLSTM	BiGRU
剧情紧凑 节奏明快 演员表现很出色 这部电影值得推荐 1	0	0	0	0	0	0


故事拖沓 剪辑混乱 看完只想立刻退场	0	1	1	1	1	1
虽然成本不高但是情感真挚细节打动人	1	0	0	0	0	0
台词空洞 表演生硬配乐也非常吵闹	0	1	1	1	1	1
前半段稍慢 后半段反转精彩整体超出预期	1	0	0	0	0	0
宣传很热闹实际内容乏味完全浪费时间	0	1	1	1	1	1

为了进一步评估跨域鲁棒性，本实验额外从公开 GitHub 数据集 `weibo2018` 中抽取了 100 条带标签微博文本作为外部测试集，其中正样本 50 条、负样本 50 条。该数据与原任务的中文影评语料存在明显领域差异，包含口语表达、话题标签、表情符号和微博语体，因此能更直接反映模型面对分布偏移时的稳定性。

外部样本分词后共有 4769 个 token，其中只有 54.92% 能在训练词表中命中，显著低于原训练语料的词向量覆盖率。这说明模型在跨域场景下不仅要面对表达习惯变化，还会遭遇更严重的词汇失配问题。

模型	测试集 Acc	测试集 F1	外部集 Acc	外部集 F1	Acc 下降	F1 下降
MLP	0.8645	0.8619	0.3100	0.1481	0.5545	0.7137
TextCNN	0.8537	0.8516	0.2700	0.1609	0.5837	0.6907
BiRNN	0.8401	0.8384	0.3200	0.2444	0.5201	0.5939
BiLSTM	0.8618	0.8625	0.3100	0.2737	0.5518	0.5888
BiGRU	0.8509	0.8525	0.3000	0.2857	0.5509	0.5668

图 8-1 原测试集与外部测试集 F1 对比



从对比结果看，所有模型在原测试集上的 Accuracy 都在 0.84 以上，但迁移到微博数据后，Accuracy 仅剩 0.27 到 0.32，F1 仅剩 0.15 到 0.29；即使下降最小的模型，其 Accuracy 和 F1 也分别下降了 0.5201 与 0.5668。按外部集 Accuracy 看，表现最好的是 BiRNN；按外部集 F1 看，表现最好的是 BiGRU。这说明当前模型更多学习到了影评领域中的局部搭配和表达分布，而不是能够稳定迁移到通用中文情感场景的抽象判别规则，因此其跨域鲁棒性较弱。

9. 心得体会

本次实验让我更直观地体会到：在已经有较好词向量表示的前提下，结构设计的核心差异并不在“能不能学到语义”，而在“如何组织语义”。MLP 更像低成本平均，TextCNN 更偏向抓取情绪触发片段，BiRNN/BiLSTM/BiGRU 更强调上下文流动。真正决定实验质量的，除了模型结构，还包括数据清洗、初始化策略、验证集早停、参数对比和曲线分析是否严谨。